


E-BOOK / PROJETO DIO

DO DADO À DECISÃO

Ciência de dados aplicada à atuária
Um guia prático com Python



PERGUNTA / DADOS / INDICADORES / DECISÃO

PAULO BERNARDO

Projeto educacional desenvolvido com apoio de IA

Outubro de 2026

COMECE AQUI

Um guia para começar

Este guia mostra como transformar uma pergunta de negócio em uma análise descritiva de risco. Com uma carteira fictícia, você vai calcular indicadores, comparar grupos e explicar os resultados.

Para estudantes e profissionais iniciantes. Os exemplos usam operações básicas e incluem código Python reproduzível. Leia a sequência completa ou consulte os capítulos pelo sumário.

Página	Conteúdo
3	Escreva uma pergunta útil
4	Três indicadores, três unidades
5	Conheça a carteira fictícia
6	Valide antes de calcular
7	Calcule o segmento A
8	Compare grupos com cuidado
9	A carteira pede ponderação
10	Reproduza em Python
11	Explique o resultado e o limite
12	Separe descrição de previsão
13	Use IA com uma tarefa clara
14	Pratique e confira
15	Fontes e termos essenciais

O QUE VOCÊ VAI PRODUZIR

Uma análise de frequência, severidade e custo por exposição, com código e interpretação.

01 / PROBLEMA

Escreva uma pergunta útil

Antes de abrir uma base, defina a decisão que a análise pretende apoiar. Uma pergunta ampla, como “qual grupo tem mais risco?”, mistura fenômenos diferentes. Quantidade de ocorrências, custo médio e volume de exposição precisam ser considerados separadamente.

A pergunta deste projeto

PERGUNTA CENTRAL

Como o custo observado por contrato-ano varia entre quatro segmentos de uma carteira fictícia, durante o mesmo período?

Essa pergunta define a unidade de comparação, o período e o indicador. Primeiro descrevemos o histórico. Uma previsão exigiria hipóteses e uma avaliação adicional.

- Qual é o período observado?
- Os grupos têm a mesma definição de sinistro e de custo?
- A exposição está medida de forma comparável?
- Que informação falta para explicar as diferenças?

Transforme a pergunta em uma entrega

Uma entrega pequena pode conter uma tabela, um gráfico e três frases: o principal resultado, a hipótese que sustenta a comparação e a limitação que o leitor precisa conhecer. Esse formato facilita a conversa entre quem analisa e quem decide.

02 / CONCEITOS

Três indicadores, três unidades

Use E para exposição, N para quantidade de sinistros e C para o custo total associado a esses sinistros. No caso do guia, exposição é o tempo de cobertura somado, em contratos-ano. Dois contratos ativos por meio ano equivalem a um contrato-ano.

$$\text{Frequência} = N / E$$

Sinistros por contrato-ano

$$\text{Severidade} = C / N$$

Reais por sinistro, quando $N > 0$

$$\text{Custo por exposição} = C / E$$

Reais por contrato-ano

Quando $N > 0$, multiplicar frequência por severidade também resulta em C / E . Essa é uma identidade entre os indicadores observados. As definições são compatíveis com o exemplo de seguros da referência [1].

FREQUÊNCIA NÃO É AUTOMATICAMENTE PROBABILIDADE

Uma pessoa ou contrato pode registrar mais de um sinistro. A razão N / E é uma taxa de ocorrências por exposição, não uma porcentagem de pessoas afetadas.

Se não há sinistros, a severidade observada fica indefinida. Com $N = 0$ e $C = 0$, o custo por exposição é zero, mas isso não demonstra ausência de risco futuro.

03 / BASE DE DADOS

Conheça a carteira fictícia

Os quatro registros abaixo foram criados para este projeto. Todos representam um período comum. O custo de cada segmento está inteiramente apurado e corresponde aos sinistros contabilizados na mesma linha.

Grupo	Exposição	Sinistros	Custo (R\$)
A	1.000	20	100.000,00
B	800	24	180.000,00
C	1.200	12	72.000,00
D	400	16	160.000,00

Dicionário dos campos

- segmento: identificação fictícia do grupo, de A a D.
- exposicao_contratos_ano: soma do tempo coberto, em contratos-ano.
- sinistros: quantidade de ocorrências contabilizadas.
- custo_total: custo associado às ocorrências, em reais.

No arquivo JSON, os valores monetários são textos com ponto decimal, como “100000.00”. O script usa Decimal para realizar as operações sem passar pelo tipo float. Os números da edição em português usam vírgula decimal e ponto para separar milhares.

ESCOPO DO EXEMPLO

A base está agregada por segmento. Ela permite cálculos descritivos; não contém o histórico individual necessário para estudar diferenças entre contratos.

04 / QUALIDADE

Valide antes de calcular

Um indicador pode estar aritmeticamente correto e ainda responder à pergunta errada. Antes do cálculo, confira a estrutura da base e o significado de cada variável. A validação técnica complementa a revisão das regras do negócio.

O que o script verifica

- Todos os registros têm os quatro campos obrigatórios.
- Os rótulos dos segmentos são textos não vazios e únicos após padronização.
- A exposição é positiva e os valores numéricos são finitos.
- O número de sinistros é um inteiro não negativo.
- O custo é não negativo. Neste caso, custo positivo requer sinistros contabilizados.

O que ainda depende de revisão

O arquivo não prova que os períodos, as coberturas ou os critérios de apuração são comparáveis. Essa informação precisa acompanhar a coleta e a documentação. Também é preciso distinguir um registro duplicado de dois registros legítimos de períodos diferentes.

UMA REGRA ÚTIL

Não substitua automaticamente um valor ausente por zero. Ausência de informação e ausência de ocorrência têm significados diferentes.

Neste projeto, uma inconsistência interrompe a análise com uma mensagem. Isso torna a correção explícita e evita que um dado inválido desapareça silenciosamente.

05 / EXEMPLO RESOLVIDO

Calcule o segmento A

O segmento A tem 1.000 contratos-ano, 20 sinistros e custo total de R\$ 100.000. Vamos usar a mesma linha para calcular os três indicadores.

$$20 / 1.000 = 0,02$$

Frequência: 0,02 sinistro por contrato-ano

Outra forma de apresentar o resultado é dizer que foram observados dois sinistros a cada cem contratos-ano.

$$100.000 / 20 = 5.000$$

Severidade: R\$ 5.000 por sinistro

Esse valor resume o custo médio das ocorrências. Não informa o custo de cada sinistro individual, que poderia variar bastante.

$$100.000 / 1.000 = 100$$

Custo por exposição: R\$ 100 por contrato-ano

A conferência pela identidade dá o mesmo resultado: $0,02 \times \text{R\$ } 5.000 = \text{R\$ } 100$ por contrato-ano.

COMO INTERPRETAR


No período e nas condições do exemplo, o grupo A apresentou esse custo médio por exposição. O cálculo é histórico e não constitui o preço comercial de um seguro.

06 / VISUALIZAÇÃO

Compare grupos com cuidado

Compare os quatro grupos com as mesmas unidades. “Sin./100” indica sinistros a cada cem contratos-ano.

Grupo	Sin./100	Severidade (R\$)	Custo/exp. (R\$)
A	2,00	5.000,00	100,00
B	3,00	7.500,00	225,00
C	1,00	6.000,00	60,00
D	4,00	10.000,00	400,00



Fonte: carteira sintética do projeto. Valores observados.

Neste caso, D tem o maior custo por exposição. A linha tracejada indica o valor ponderado da carteira, explicado na próxima página.

UMA DIFERENÇA PEDE INVESTIGAÇÃO

Observe também a quantidade de sinistros, o volume de exposição e a composição do grupo. O gráfico descreve os registros; não identifica sozinho a causa da diferença.

07 / AGREGAÇÃO

A carteira pede ponderação

Os segmentos têm tamanhos diferentes. Para calcular o indicador da carteira, some primeiro os custos e as exposições. Assim, cada contrato-ano tem o mesmo peso no resultado final.

Exposição total	Sinistros	Custo total (R\$)
3.400	72	512.000,00

512.000 / 3.400 = 150,588235...

Custo por exposição da carteira: R\$ 150,59

A média simples dos quatro indicadores seria $(100 + 225 + 60 + 400) / 4 = \text{R\$ } 196,25$. Nesse cálculo, cada segmento recebe o mesmo peso, embora represente uma parcela diferente da exposição.

A média ponderada equivale a $(1.000 \times 100 + 800 \times 225 + 1.200 \times 60 + 400 \times 400) / 3.400$. Ela reproduz a razão entre o custo total e a exposição total.

Confira também os outros totais

Frequência: $72 / 3.400 =$ aproximadamente 0,021176 sinistro por contrato-ano. Severidade: $\text{R\$ } 512.000 / 72 =$ aproximadamente R\$ 7.111,11 por sinistro.

ESCOLHA O PESO PELA PERGUNTA

O custo por exposição usa exposição como peso. A severidade total usa a quantidade de sinistros. Uma média de médias só é apropriada quando seus pesos fazem sentido para a medida desejada.

08 / CÓDIGO

Reproduza em Python

Depois de extrair o pacote, abra um terminal na pasta do projeto. O script completo executa as validações da página 6 e grava os resultados em output/analise_resultados.json.

```
python scripts/analisar_carteira.py
```

O trecho abaixo mostra o cálculo da carteira e pressupõe a base já validada. Ele usa somente módulos da biblioteca padrão do Python [3, 4].

```
import json
from decimal import Decimal as D
from pathlib import Path

base = Path("dados/carteira_sintetica.json")
linhas = json.loads(base.read_text(encoding="utf-8"))

e = sum(D(str(r["exposicao_contratos_ano"]))
        for r in linhas)
n = sum(r["sinistros"] for r in linhas)
c = sum(D(r["custo_total"]) for r in linhas)

frequencia = D(n) / e
severidade = c / D(n)
custo_por_exposicao = c / e

print(f"Frequência: {frequencia:.6f}")
print(f"Severidade: R$ {severidade:.2f}")
print(f"Custo/exposição: R$ {custo_por_exposicao:.2f}")
```

SAÍDA ESPERADA

Frequência: 0.021176; severidade: R\$ 7111.11; custo/exposição: R\$ 150.59. O terminal usa ponto decimal; o livro apresenta os mesmos valores com formatação brasileira.

09 / INTERPRETAÇÃO

Explique o resultado e o limite

Uma boa síntese começa pelo que foi observado e indica o que ainda precisa ser investigado. No exemplo, a carteira apresentou R\$ 150,59 por contrato-ano, e o segmento D teve o maior valor entre os quatro grupos.

Um exemplo de comunicação

SÍNTESE PARA APRESENTAÇÃO

“Na carteira fictícia, o custo observado foi de R\$ 150,59 por contrato-ano. O segmento D ficou acima do total. Para explicar a diferença, seria necessário revisar a composição dos grupos, a quantidade de sinistros e os critérios de apuração.”

Perguntas para aprofundar

- Os contratos têm coberturas e limites semelhantes?
- Há poucos sinistros de alto custo concentrados em um grupo?
- O período é representativo ou houve uma ocorrência excepcional?
- Os custos estão suficientemente apurados para a comparação?

Os quatro totais agregados não permitem medir a variabilidade entre sinistros individuais, separar fatores explicativos ou comprovar uma relação causal. Registrar essa limitação ajuda o leitor a usar o resultado na medida certa.

Para avançar, seria necessário obter dados mais detalhados e comparáveis, mantendo a documentação das definições e da origem de cada campo.

10 / PRÓXIMOS PASSOS

Separe descrição de previsão

Descrever o histórico e prever o futuro são tarefas diferentes. No primeiro caso, calculamos razões entre valores observados. No segundo, buscamos estimar um resultado ainda não conhecido e precisamos avaliar o erro dessa estimativa.

Um processo mínimo de avaliação

- Defina o alvo e as informações disponíveis na data da previsão.
- Separe dados de desenvolvimento e avaliação antes de aprender transformações.
- Escolha uma forma de divisão compatível com o período e com registros repetidos.
- Compare o modelo a uma referência simples e examine seus erros.

Vazamento de dados ocorre quando a construção do modelo utiliza informação que não estaria disponível na previsão. Isso pode produzir uma avaliação otimista [2].

NESTE PROJETO

Não ajustamos um modelo preditivo: há apenas quatro linhas agregadas. O objetivo é aprender indicadores, ponderação e reprodução de uma análise descritiva.

Uma projeção simples pode usar uma frequência histórica como hipótese. Se as condições mudarem, essa hipótese precisa ser revista. Mesmo quando a estimativa parece razoável, o resultado realizado continuará sujeito à incerteza.

11 / PROMPTS

Use IA com uma tarefa clara

A IA pode ajudar a organizar explicações, propor uma estrutura e escrever uma primeira versão de código. Para obter uma resposta útil, descreva a tarefa, os dados, as restrições e o formato esperado. Depois confira o resultado com os valores do caso.

Um prompt para revisar a análise

EXEMPLO APLICADO

“Revise os indicadores de uma carteira fictícia com quatro segmentos. Confira se o total usa somas de custos e exposição. Explique a diferença entre frequência e probabilidade. Não apresente o custo histórico como preço comercial. Liste os pontos a corrigir.”

Como os prompts foram organizados

- 01: título, público e estrutura do e-book.
- 02: conteúdo e caso numérico.
- 03: revisão das unidades e dos resultados.
- 04: briefing de diagramação.
- 05: artigo e documentação do repositório.

O roteiro editorial, o código e os textos foram preparados com apoio de IA. O PDF foi montado com ReportLab, o gráfico foi produzido com Matplotlib e a capa usa elementos vetoriais. As ferramentas efetivamente usadas estão documentadas no README.

Os prompts completos fazem parte do repositório, para que o processo possa ser entendido, revisado e adaptado.

12 / EXERCÍCIOS

Pratique e confira

1. Um novo segmento

Um grupo fictício apresenta 500 contratos-ano, 10 sinistros e custo total de R\$ 60.000. Calcule frequência, severidade e custo por exposição.

RESPOSTA 1

Frequência = $10 / 500 = 0,02$ sinistro por contrato-ano. Severidade = $R\$ 60.000 / 10 = R\$ 6.000$ por sinistro. Custo por exposição = $R\$ 60.000 / 500 = R\$ 120$ por contrato-ano.

2. Uma hipótese para o próximo período

Se a frequência de A fosse mantida em 0,02 e a exposição futura fosse de 2.000 contratos-ano, qual seria o número esperado de sinistros?

RESPOSTA 2

$2.000 \times 0,02 = 40$ sinistros esperados, sob a hipótese de manutenção da frequência. Esperado não significa garantido.

3. A média da carteira

Por que R\$ 196,25 não representa o custo por exposição da carteira original?

RESPOSTA 3

Esse número dá o mesmo peso a cada segmento. A carteira exige ponderação pela exposição: $R\$ 512.000 / 3.400 = R\$ 150,59$ por contrato-ano.

Para uma extensão, altere um valor no JSON, execute novamente o script e explique o efeito nos indicadores. Atualize o texto e os gráficos antes de publicar uma nova edição do e-book.

REFERÊNCIAS

Fontes e termos essenciais

Os valores e as conclusões numéricas deste guia foram criados para o caso fictício. As fontes abaixo sustentam os conceitos e documentam as ferramentas. Consulta em 7 de outubro de 2026.

[1] scikit-learn: Tweedie regression on insurance claims. Definições de frequência, severidade e custo por exposição.

[2] scikit-learn: Common pitfalls and recommended practices. Separação de dados e prevenção de vazamento de informação.

[3] Python: módulo json. Leitura e gravação dos arquivos estruturados.

[4] Python: módulo decimal. Aritmética decimal utilizada no script.

[5] Felipe Aguiar: projeto de referência da DIO. Inspiração para o fluxo de criação do e-book com prompts.

Glossário de bolso

- Exposição: volume de cobertura, considerando o tempo observado.
- Frequência: quantidade de sinistros por unidade de exposição.
- Severidade: custo médio por sinistro contabilizado.
- Ponderação: escolha de pesos adequados à medida agregada.
- Reprodução: obtenção dos mesmos resultados a partir dos arquivos e do código.

SOBRE ESTA EDIÇÃO

Projeto educacional de Paulo Bernardo, estudante de Ciências Atuariais, desenvolvido com apoio de inteligência artificial. O material descreve um caso sintético para estudo e portfólio.